

Descripción y análisis exploratorio de datos

Materia: Análisis de Series de Tiempo y Pronósticos (1C-2026)

Grupo: 9

Integrantes:

- Lucas Achaval - Email: lachavalrodriguez@estudiantes.unsam.edu.ar
- Marcos Achaval - Email: machavalrodriguez@unsam-bue.edu.ar

Enlace al conjunto de datos original: Dataset propio de estación meteorológica de club náutico en Potrerillos (archivo local: data/station_15338.csv).

Descripción breve del conjunto de datos y su origen

Este conjunto de datos proviene de una estación meteorológica instalada en un club náutico en Potrerillos, Mendoza. La estación registra una observación por minuto con variables de viento (mínimo, promedio, máximo y rachas), dirección, temperatura, humedad relativa y presión atmosférica.

El archivo contiene datos desde 2025-08-01 hasta 2026-04-14, y representa mediciones reales en un entorno de montaña donde el viento térmico tiene un comportamiento diario marcado.

Problema o pregunta a resolver

Potrerillos, en la zona del embalse, es un entorno montañoso donde predominan los **vientos térmicos** (condicionados por diferencias de temperatura a lo largo del día). El régimen diurno de verano es muy definido: intensidades bajas de madrugada, aumento progresivo por la mañana, máximo al mediodía y disminución por la tarde. Cuando supera los 10 kt, el viento sopla predominantemente desde el sector **ENE ($\approx 75^\circ$)**, como se verifica en la sección 4.c.

Los pronósticos disponibles suelen subestimar los máximos diarios y no capturan bien la señal térmica local. Por eso desarrollamos un modelo de pronóstico de viento para este lugar, enfocado en la **intensidad** (variable objetivo: `wind_avg`), no en la dirección.

- **Métricas:** MAE, RMSE, R^2 .
- **Horizonte:** 12 horas, con 12 predicciones a futuro (una por hora).
- **Preprocesamiento:** agregación horaria por mediana para variables continuas; prior físico (dirección dominante del régimen fuerte) para la dirección del viento.

Importación

In [323... `import pandas as pd`

```
df = pd.read_csv("../data/station_15338.csv")
df.set_index(pd.to_datetime(df["datetime"]), inplace=True)
df.drop(columns=["datetime", "unixtime"], inplace=True)
df.head(10)
```

Out [323...

	wind_avg	wind_max	wind_min	wind_direction	temperature	rh	mslp
datetime							
2025-08-01 00:01:00	8.9	11.3	NaN	61.0	10.0	73.0	855.1
2025-08-01 00:02:00	8.7	11.3	NaN	73.0	10.0	73.0	855.1
2025-08-01 00:03:00	12.0	14.8	NaN	57.0	10.0	73.3	855.2
2025-08-01 00:04:00	8.7	14.8	NaN	61.0	10.0	73.0	855.2
2025-08-01 00:05:00	7.8	14.8	NaN	73.0	10.0	73.5	855.2
2025-08-01 00:06:00	7.4	11.6	NaN	67.0	9.9	73.0	855.2
2025-08-01 00:07:00	8.5	11.3	NaN	70.0	9.9	73.8	855.2
2025-08-01 00:08:00	10.5	13.4	NaN	81.0	9.9	73.0	855.2
2025-08-01 00:09:00	11.3	13.4	NaN	89.0	9.9	72.8	855.1
2025-08-01 00:10:00	11.5	14.2	NaN	91.0	9.9	72.0	855.1

Resampleo

In [324... `df = df.resample("1h").median().asfreq("1h")`

Análisis exploratorio de datos

4.a) ¿Por qué este conjunto debe abordarse como serie de tiempo?

El conjunto de datos está ordenado cronológicamente y cada observación depende del instante de medición. Por lo tanto, el orden temporal no es intercambiable y es por esto que debemos tratar el problema como una serie de tiempo.

4.b) Relación entre cada paso y el tiempo real

```
In [325... import numpy as np

raw_index = pd.to_datetime(
    pd.read_csv("../data/station_15338.csv", usecols=["datetime"])["datetime"]
)
intervals = raw_index.diff().dt.total_seconds() / 60

print("Cadencia nativa (datos crudos, minutos entre registros):")
print(
    f"mínimo: {intervals.min():.2f}, \npromedio: {intervals.mean():.2f}, \nmediana: {intervals.median():.2f}, \nmáximo: {intervals.max():.2f}"
)

print(f"\nValor mínimo de tiempo: {raw_index.min()}")
print(f"Valor máximo de tiempo: {raw_index.max()}")
```

Cadencia nativa (datos crudos, minutos entre registros):
mínimo: 1.00,
promedio: 1.05,
mediana: 1.00,
máximo: 5761.00

Valor mínimo de tiempo: 2025-08-01 00:01:00
Valor máximo de tiempo: 2026-04-14 00:00:00

La cadencia nativa es de 1 minuto entre registros (mediana y mínimo = 1.00). El promedio de 1.05 min y el máximo de 5761 min (~4 días) evidencian interrupciones puntuales del registro por caídas de la estación. El índice abarca desde el 1 de agosto de 2025 hasta el 14 de abril de 2026.

Para el análisis posterior trabajamos sobre la serie resampleada a 1 hora, donde el paso es uniforme de 60 min.

4.c) Valores faltantes: diagnóstico, completado e impacto

```
In [326... nas = pd.DataFrame(df.isna().sum(), columns=["nas"])
nas["%"] = (nas["nas"] / len(df) * 100).round(2)
nas
```

Out [326...

	nas	%
wind_avg	276	4.49
wind_max	276	4.49
wind_min	6145	100.00
wind_direction	276	4.49
temperature	276	4.49
rh	276	4.49
mslp	276	4.49
gustiness	276	4.49

Hay faltantes en `wind_direction`, `mslp` y `gustiness`, y `wind_min` no tiene datos válidos (100% NaN).

Estrategia:

- `wind_min` : descartar.
- Continuas: interpolación temporal con `limit=6` (huecos ≤ 6 h).
- Huecos > 6 h: dejar como NaN y excluirlos de las ventanas de entrenamiento.

La imputación evita pérdida masiva de filas pero puede suavizar extremos y reducir variabilidad real. Conviene verificar robustez comparando con/sin imputación.

Verificación: dirección del viento en régimen fuerte

En Potrerillos el viento térmico predominante sopla desde el ENE. Verificamos si cuando `wind_avg  $\geq 10$  kt` la dirección está fuertemente concentrada en un sector.

In [327...

```
import matplotlib.pyplot as plt


strong_wind = df[df["wind_avg"] >= 10]["wind_direction"].dropna()
print(f"Registros con wind_avg  $\geq 10$ : {len(strong_wind)}")
print(strong_wind.describe().round(2))

fig, ax = plt.subplots(figsize=(8, 3))
strong_wind.hist(bins=36, ax=ax)
ax.set_xlabel("wind_direction (°)")
ax.set_title("Distribución de dirección cuando wind_avg  $\geq 10$  kt")
plt.tight_layout()
```

Registros con `wind_avg` ≥ 10 : 1058

```
count    1058.00
mean      76.27
std       18.87
min       51.00
25%      65.00
50%      74.00
75%      81.00
max      329.00
```

Name: `wind_direction`, dtype: float64



Estrategia de imputación

- **`wind_min`** : descartada (100% NaN).
- **Huecos cortos (≤ 6 h)** en variables continuas: interpolación lineal temporal (`limit=6`).
- **Huecos largos (> 6 h)**: corresponden a períodos offline de la estación — se dejan como NaN y se excluyen de las ventanas de entrenamiento.
- **`wind_direction`** :
 - Si `wind_avg` ≥ 10 y dirección es NaN $\rightarrow$ se imputa con la dirección dominante del régimen fuerte (prior físico).
 - Restante: forward-fill limitado a 6 h (viento débil, dirección poco relevante).

```
In [328... df.drop(columns=["wind_min"], inplace=True)

dominant_dir = df[df["wind_avg"] >= 10]["wind_direction"].dropna().mode()[0]
print(f"Dirección dominante (wind_avg  $\geq 10$ ): {dominant_dir}°")

for col in ["wind_avg", "wind_max", "temperature", "rh", "mslp", "gustiness":
    df[col] = df[col].interpolate(method="time", limit=6)

mask_strong_nan = (df["wind_avg"] >= 10) & df["wind_direction"].isna()
df.loc[mask_strong_nan, "wind_direction"] = dominant_dir
df["wind_direction"] = df["wind_direction"].ffill(limit=6)

print("\nNaN restantes (huecos offline > 6h):")
print(df.isna().sum()[df.isna().sum() > 0])
```

Dirección dominante ($\text{wind_avg} \geq 10$): 77.0°

NaN restantes (huecos offline > 6h):

```
wind_avg      231
wind_max      231
wind_direction 231
temperature    231
rh            231
mslp          231
gustiness     231
dtype: int64
```

4.d) Tipos de Datos, Variables endogenas y exogenas

In [329... `df.dtypes`

```
Out[329... wind_avg      float64
wind_max      float64
wind_direction float64
temperature    float64
rh            float64
mslp          float64
gustiness     float64
dtype: object
```

Todas las variables son `float64` (numéricas continuas).

Endógenas (dinámica del sistema): `wind_avg` (objetivo), `wind_max`, `wind_direction`, `gustiness`. **Exógenas** (condicionan el sistema): `temperature` (driver térmico), `rh`, `mslp` (estado sinóptico).

Las exógenas pueden usarse como predictores sin riesgo de *data leakage* si sus valores son conocidos o pronosticados independientemente al momento del pronóstico.


4.e) Descomposición estacional

```
In [330... from statsmodels.tsa.seasonal import seasonal_decompose
import matplotlib.pyplot as plt

wind_filled = df["wind_avg"].ffill().bfill()

sd = seasonal_decompose(
    wind_filled, model="additive", period=24, extrapolate_trend="freq"
)
fig = sd.plot()
fig.set_size_inches(11, 6)
plt.suptitle("Descomposición aditiva de wind_avg (período=24h)", y=1.01)
plt.tight_layout()
```

Descomposición aditiva de wind_avg (período=24h)



- **Tendencia:** no plana. Vientos más débiles al inicio (agosto 2025, fin del invierno) y más intensos hacia la primavera-verano austral (sep 2025 – feb 2026), coherente con la mayor actividad térmica de la temporada cálida. Marzo-abril 2026 (otoño) vuelve a descender.
- **Estacionalidad:** componente diaria muy limpia y regular (± 2.5 kt). Máximos durante el día y mínimos de madrugada.
- **Residuo:** disperso entre 2 y 5 kt con outliers, conserva cierta estructura $\rightarrow$ no es ruido blanco puro (ver 4.f).

4.f) Estacionariedad y extracción de residuos estacionarios

```
In [331]: from statsmodels.tsa.stattools import adfuller

period = 24

print("--- Serie original (wind_avg) ---")
ADF_result = adfuller(df["wind_avg"].dropna())
print(f"ADF Statistic: {ADF_result[0]:.3f}")
print(f"p-value: {ADF_result[1]:.3e}")
print("Critical Values:")
for key, value in ADF_result[4].items():
    print(f"    {key}: {value:.3f}")

print()

print("--- Residuo de la descomposición ---")
ADF_result = adfuller(sd.resid[period:-period].dropna())
print(f"ADF Statistic: {ADF_result[0]:.3f}")
print(f"p-value: {ADF_result[1]:.3e}")
print("Critical Values:")
```

```
for key, value in ADF_result[4].items():
    print(f"    {key}: {value:.3f}")
```

--- Serie original (wind_avg) ---

ADF Statistic: -11.532

p-value: 3.812e-21

Critical Values:

1%: -3.431

5%: -2.862

10%: -2.567

--- Residuo de la descomposición ---

ADF Statistic: -23.396

p-value: 0.000e+00

Critical Values:

1%: -3.431

5%: -2.862

10%: -2.567

La prueba ADF evalúa:

- H_0 : la serie tiene raíz unitaria (no es estacionaria).
- H_1 : la serie es estacionaria.

Serie original: el ADF Statistic (-11.53) es menor que el valor crítico al 1% (-3.43) y el p-value es prácticamente cero → se rechaza H_0 → **la serie es estacionaria**.

Residuo: el ADF Statistic (-23.40) refuerza aún más el rechazo de H_0 → **el residuo también es estacionario**.

Que la serie sea estacionaria es consistente con la naturaleza física del viento: es un proceso de reversión a la media sin tendencia acumulativa. Por lo tanto, no es necesario diferenciar la serie para modelarla.

4.g) Autocorrelación y autocorrelacion parcial

In [332...


```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import matplotlib.pyplot as plt

fig, axes = plt.subplots(1, 2, figsize=(12, 3.5))

plot_acf(df["wind_avg"].dropna(), lags=48, bartlett_confint=False, ax=axes[0])
axes[0].set_title("ACF - wind_avg")
axes[0].set_xlabel("Lag (horas)")

plot_pacf(df["wind_avg"].dropna(), lags=48, ax=axes[1])
axes[1].set_title("PACF - wind_avg")
axes[1].set_xlabel("Lag (horas)")

plt.tight_layout()
```

- La ACF cae lenta con picos pronunciados en los lags 24 y 48, confirmando la **estacionalidad diaria**.
- La PACF cae abruptamente luego del lag 1 (≈ 0.85) y se mantiene dentro de las bandas de error desde el lag 3 — estructura compatible con un proceso **AR(1)**.

El residuo de la descomposición (no mostrado) conserva autocorrelación en lags cortos y un pico en lag 24, indicando que la descomposición captura la forma media del ciclo diario pero no remueve toda la estructura periódica.

4.h) Período entre registros y espectro de potencias

```
In [333... import numpy as np
import matplotlib.pyplot as plt

wind_filled = df["wind_avg"].ffill().bfill()
wind_centered = wind_filled - wind_filled.mean()
NT = len(wind_centered)

wind_f = np.fft.rfft(wind_centered.values)
armonics = np.arange(0, len(wind_f))
wind_f_adj = wind_f * 2 / NT
sqamp = np.real(wind_f_adj) ** 2 + np.imag(wind_f_adj) ** 2

print(f"Período entre registros: 1 hora ( $\Delta t = 1h$ ). Nyquist: 12 ciclos/día.")
print(f"Varianza: {np.var(wind_centered):.4f} | Parseval: {0.5*np.sum(sqamp)}")

freqs_per_day = armonics * 24 / NT

mw = 10
weights = np.ones(2 * mw + 1)
ps = 0.5 * np.convolve(NT * sqamp, weights, mode="same") / (2 * mw + 1)
ps = ps[mw :: 2 * mw + 1]
fs = armonics[mw :: 2 * mw + 1] * 24 / NT

fig, axes = plt.subplots(1, 2, figsize=(11, 3))
axes[0].stem(freqs_per_day, sqamp, markerfmt="C0o", basefmt="C0-", linefmt="")
axes[0].set_xscale("log")
axes[0].set_xlabel("Frecuencia (ciclos/día)")
axes[0].set_title("Periodograma")
axes[0].axvline(x=1, color="r", linestyle="--", label="1/día")
axes[0].axvline(x=2, color="orange", linestyle="--", label="2/día")
```

```


axes[0].legend()

axes[1].plot(fs, ps)
axes[1].set_xscale("log")
axes[1].set_xlabel("Frecuencia (ciclos/día)")
axes[1].set_title(f"Espectro de potencias (ventana {2*mw+1})")
axes[1].axvline(x=1, color="r", linestyle="--")
axes[1].axvline(x=2, color="orange", linestyle="--")

plt.tight_layout()

```

Período entre registros: 1 hora ($\Delta t = 1h$). Nyquist: 12 ciclos/día.
 Varianza: 14.0342 | Parseval: 14.0342



El período entre registros es de **1 hora** (Nyquist = 12 ciclos/día). La identidad de Parseval se verifica (varianza = 14.03 en ambos dominios).

- **Pico dominante en 1 ciclo/día (24h):** concentra la mayor parte de la varianza — ciclo térmico diario.
- **Armónico en 2 ciclos/día (12h):** presente pero ~5× menos potente.
- **Fondo de baja frecuencia:** variabilidad sinóptica de multi-días.

La variabilidad de `wind_avg` está dominada por el ciclo diario de 24h, coherente con el viento térmico del embalse.

5. Modelo de regresión

Se propone una **regresión lineal** con lags como modelo inicial:

- La PACF mostró dependencia predominantemente AR(1).
- Linealidad como primera hipótesis razonable, comparable contra línea de base.
- 24 lags (ventana de 24h) permiten capturar corto plazo y ciclo diario.

Enfoque de **pronóstico directo**: un sub-modelo por cada paso del horizonte de 12h.

Líneas de base: **persistencia** (repite último valor) y **media** (predice la media de entrenamiento). Validación con `TimeSeriesSplit` (3 folds).

```

In [334... import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

```

```

from sklearn.base import BaseEstimator, RegressorMixin
from sklearn.model_selection import TimeSeriesSplit
from sklearn.metrics import root_mean_squared_error, mean_absolute_error, r2

pasos = 24
avance = 12

wind = df["wind_avg"]

X = pd.DataFrame({"Lag_0": wind})
for i in range(1, pasos + 1):
    X[f"Lag_{i}"] = wind.shift(i)

for i in range(1, avance + 1):
    X[f"Adv_{i}"] = wind.shift(-i)

X = X.dropna()
print(f"Dataset: {X.shape[0]} filas x {X.shape[1]} columnas")
X.head(3)

```

Dataset: 5662 filas x 37 columnas

Out[334...

	Lag_0	Lag_1	Lag_2	Lag_3	Lag_4	Lag_5	Lag_6	Lag_7	Lag_8	Lag_9
datetime										
2025-08-02 00:00:00	5.25	5.20	7.90	6.05	4.30	4.60	3.6	7.85	10.05	12.50
2025-08-02 01:00:00	5.85	5.25	5.20	7.90	6.05	4.30	4.6	3.60	7.85	10.05
2025-08-02 02:00:00	3.10	5.85	5.25	5.20	7.90	6.05	4.3	4.60	3.60	7.85

3 rows x 37 columns

In [335...

```

class LastValueEstimator(RegressorMixin, BaseEstimator):
    def fit(self, X, y=None):
        self.is_fitted_ = True
        return self

    def predict(self, X):
        if isinstance(X, pd.DataFrame):
            return X.iloc[:, 0].values # Lag_1 = último valor observado
        return X[:, 0]

class MeanEstimator(RegressorMixin, BaseEstimator):
    def fit(self, X, y=None):
        if isinstance(X, pd.DataFrame):
            self.mean_ = X.iloc[:, 0].mean()
        else:
            self.mean_ = X[:, 0].mean()

```

```

        self.is_fitted_ = True
        return self

    def predict(self, X):
        return np.repeat(self.mean_, X.shape[0])

tscv = TimeSeriesSplit(n_splits=3)
lr = LinearRegression()
me = MeanEstimator()
lv = LastValueEstimator()

train_rmse_adv = np.empty(shape=[0, 3])
test_rmse_adv = np.empty(shape=[0, 3])

for adv in range(avance):
    train_rmse = np.array([])
    test_rmse = np.array([])
    for train, test in tscv.split(X):
        X_lags_train = X.iloc[train, 1 : pasos + 1] # Lag_1 .. Lag_24
        y_train = X.iloc[train, pasos + 1 + adv] # Adv_(adv+1)
        X_lags_test = X.iloc[test, 1 : pasos + 1]
        y_test = X.iloc[test, pasos + 1 + adv]

        for model in [lr, me, lv]:
            model.fit(X_lags_train, y_train)
            train_rmse = np.append(
                train_rmse,
                root_mean_squared_error(y_train, model.predict(X_lags_train))
            )
            test_rmse = np.append(
                test_rmse, root_mean_squared_error(y_test, model.predict(X_l
            )


    train_rmse_adv = np.append(
        train_rmse_adv,
        [
            [
                np.mean(train_rmse[0::3]),
                np.mean(train_rmse[1::3]),
                np.mean(train_rmse[2::3]),
            ]
        ],
        axis=0,
    )
    test_rmse_adv = np.append(
        test_rmse_adv,
        [
            [
                np.mean(test_rmse[0::3]),
                np.mean(test_rmse[1::3]),
                np.mean(test_rmse[2::3]),
            ]
        ],
        axis=0,
    )

```

```

horizons = np.arange(1, avance + 1)
plt.figure(figsize=(10, 5))
plt.plot(horizons, test_rmse_adv[:, 0], "o-", label="Regresión Lineal")
plt.plot(horizons, test_rmse_adv[:, 1], "s--", label="Media")
plt.plot(horizons, test_rmse_adv[:, 2], "^--", label="Persistencia")
plt.xlabel("Horizonte de pronóstico (horas)")
plt.ylabel("RMSE (kt)")
plt.title("Desempeño vs. horizonte de pronóstico (validación)")
plt.xticks(horizons)
plt.legend()
plt.tight_layout()

```



```

In [336... # Métricas detalladas para el último fold, horizonte h=12
train_idx, test_idx = list(tscv.split(X))[-1]
X_lags_train = X.iloc[train_idx, 1 : pasos + 1]
y_train = X.iloc[train_idx, pasos + avance]
X_lags_test = X.iloc[test_idx, 1 : pasos + 1]
y_test = X.iloc[test_idx, pasos + avance]

lr.fit(X_lags_train, y_train)
y_pred = lr.predict(X_lags_test)

print(f"=== Regresión Lineal - horizonte h=12h (último fold) ===")
print(f"RMSE: {root_mean_squared_error(y_test, y_pred):.3f} kt")
print(f"MAE: {mean_absolute_error(y_test, y_pred):.3f} kt")
print(f"R²: {r2_score(y_test, y_pred):.3f}")

print(f"\n=== Persistencia - horizonte h=12h ===")
y_pers = X_lags_test.iloc[:, 0].values
print(f"RMSE: {root_mean_squared_error(y_test, y_pers):.3f} kt")
print(f"MAE: {mean_absolute_error(y_test, y_pers):.3f} kt")
print(f"R²: {r2_score(y_test, y_pers):.3f}")

```

=== Regresión Lineal – horizonte h=12h (último fold) ===

RMSE: 2.977 kt

MAE: 2.247 kt

R²: 0.440

=== Persistencia – horizonte h=12h ===

RMSE: 6.467 kt

MAE: 5.419 kt

R²: -1.641

Modelo	RMSE (kt)	MAE (kt)	R ²
Regresión Lineal	3.06	2.30	0.41
Persistencia	6.45	5.39	-1.63

La regresión lineal supera ampliamente a la persistencia en h=12h. El R² negativo de persistencia indica que predecir el último valor es peor que predecir la media — razonable para 12h donde el régimen pudo cambiar. La LR explica el 41% de la varianza sin features exógenas ni encodings del ciclo horario — margen claro de mejora para el TP final incorporando temperatura, presión y encoding horario.